

確率的勾配降下法

Stochastic gradient descent (SGD)

平均値の逐次計算

目的: 値 s を観測値 s_i ($i=1,2,\dots$)の平均値に近づける計算をオンライン
(データ取得ごとに)行う

学習則:

$s \leftarrow$

$$s + 1/k(s_i - s)$$

$=$


$$s + a(s_i - s)$$

($k=1$ のとき $s \leftarrow s_i$)

単純化した表記:

$\Delta s =$

$$a(s_i - s)$$



上記の学習則をちょっと違う方法で導出してみる

確率的勾配降下法: 単純な例


目的: 値 s を観測値 s_i ($i=1,2,\dots$)の平均値に近づける計算をオンライン(データ取得ごとに)行う

誤差関数: $E(s) = \frac{1}{2}(s - s_i)^2$

確率的勾配降下法: 誤差関数の値を小さくするように学習

$$\begin{aligned}\Delta s &= -\epsilon \frac{dE}{ds} \\ &= \boxed{} \\ s &\leftarrow \boxed{}\end{aligned}$$

前ページの学習則と一致



確率的勾配降下法: 単純な例

目的: 値 s を観測値 s_i ($i=1,2,\dots$)の平均値に近づける計算をオンライン(データ取得ごとに)行う

誤差関数: $E(s) = \frac{1}{2}(s - s_i)^2$

確率的勾配降下法: 誤差関数の値を小さくするように学習

$$\Delta s = -\epsilon \frac{dE}{ds}$$

$$=$$

$$s \leftarrow$$

強化学習もSGDの変形版

$$Q(s, a) \leftarrow Q(s, a) + \epsilon(r + \gamma \max_{a'} Q(s', a') - Q(s, a))$$


$$V(s) \leftarrow V(s) + \epsilon(r + \gamma V(s') - V(s))$$

確率的勾配降下法(SGD)の一般型

誤差関数 $E(\boldsymbol{w}) = \frac{1}{2}(f(x; \boldsymbol{w}) - d)^2$

学習則 $\Delta w_i = -\epsilon \frac{\partial E(\boldsymbol{w})}{\partial w_i}$

$$= -\epsilon(f(x; \boldsymbol{w}) - d) \frac{\partial f(x; \boldsymbol{w})}{\partial w_i}$$




局所解に陥りやすいため、さまざまな変形版がある

確率的勾配降下法


(SGD)の活用例

強化学習の価値関数の近似

状態数 s が連続値をとる場合 価値関数の定義方法




方法1: 状態を離散化



- $V(s)$ を正確に近似するために状態数を増やすと，学習に時間がかかる
- 隣接する状態値 s に対する価値関数 $V(s)$ は，多くの場合似た値になるので，各状態値に対して独立に学習を行うのは非効率


方法2: 関数近似法



基底関数の組み合わせで関数近似を行う


基底関数の例

Radial Basis Function (RBF, 動径基底関数)



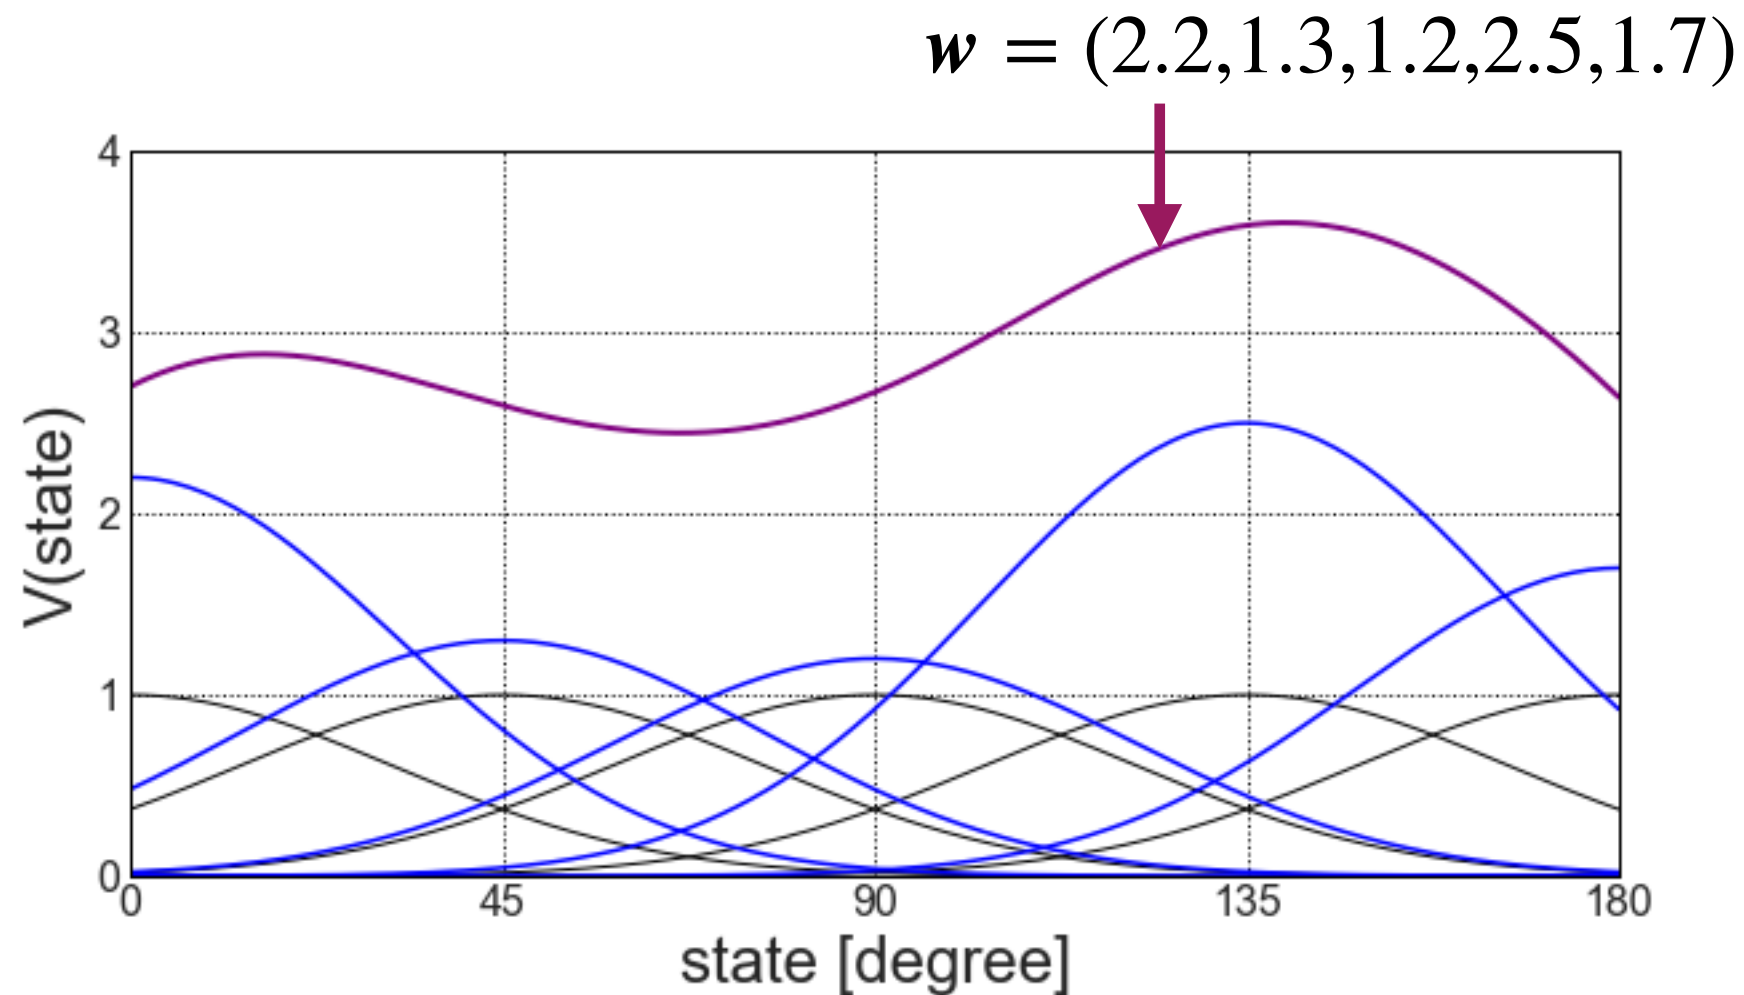
$$\phi_i(x) = \boxed{} \quad (i = 1, \dots, N)$$

RBFによる関数近似

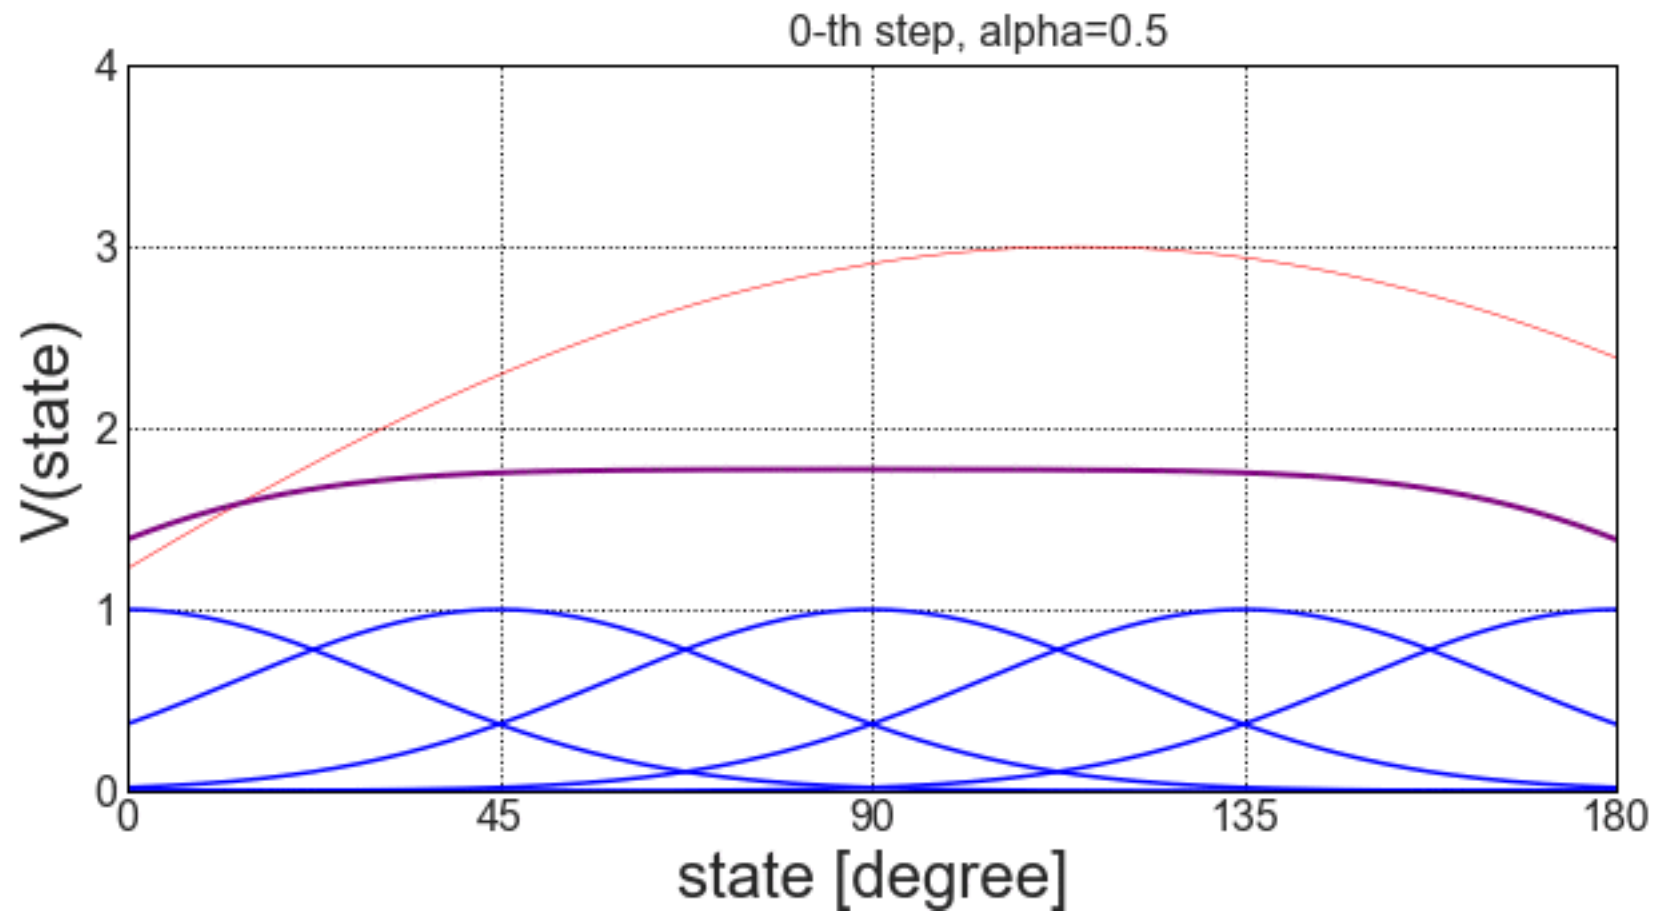


$$V(s; \mathbf{w}) = \sum_{i=1}^N w_i \phi_i(s) = \sum_{i=1}^N w_i \boxed{}$$

RBFによる関数近似



$$V(s; \mathbf{w}) = \sum_{i=1}^N w_i \phi_i(s) = \sum_{i=1}^N w_i \boxed{}$$



近似関数

$$V(s; \mathbf{w}) = \sum_{i=1}^N w_i \phi_i(s) = \sum_{i=1}^N w_i e^{-\left(\frac{s - m_i}{\sigma}\right)^2}$$

誤差関数

$$E(\mathbf{w}) = \frac{1}{2} (V(s; \mathbf{w}) - d)^2 \quad d \equiv r + \gamma V(s'; \mathbf{w})$$

学習則


Q. 価値関数 $V(s)$ の近似関数 $V(s; \mathbf{w})$ を得るための
学習則を最急降下法により導きなさい

確率的勾配降下法

(SGD)の活用例

形式ニューロンの学習

入出力関数(形式ニューロンモデル)



$$s = \sum_{i=1}^N w_i x_i - h$$


$$y = f(s) = \begin{cases} 1 & (s \geq 0) \\ 0 & (otherwise) \end{cases}$$

活性化関数はステップ関数


学習の目的

入力 (x_1, x_2) に対する出力 y が目標値 y_d に近づくようにパラメータ (結合重み) (w_1, w_2, h) を調整する

ydのdはdesired 正解の値だと思えばいい



入出力関数(形式ニューロンモデル)



$$s = \sum_{i=1}^N w_i x_i - h$$

$$y = f(s) = \begin{cases} 1 & (s \geq 0) \\ 0 & (otherwise) \end{cases}$$


活性化関数はステップ関数

誤差関数 $E = \frac{1}{2}(y - y_d)^2$


学習則 $\Delta w_i =$

$=$

$=$



入出力関数(形式ニューロンモデル)



$$s = \sum_{i=1}^N w_i x_i - h$$

$$y = f(s) = \begin{cases} 1 & (s \geq 0) \\ 0 & (otherwise) \end{cases}$$

活性化関数はステップ関数

誤差関数 $E = \frac{1}{2}(y - y_d)^2$


学習則 $\Delta w_i =$

$$\Delta w_i = -\varepsilon \frac{\delta E}{\partial w_i} = -\varepsilon \frac{dE}{dy} \frac{dy}{ds} \frac{\partial s}{\partial w_i}$$





=

=



活性化関数を線形関数に




誤差関数 $E = \frac{1}{2}(y - y_d)^2 = \frac{1}{2}(f(s) - y_d)^2$

学習則 $\Delta w_i =$

$=$

$=$

入出力関数(形式ニューロンモデル)



$$s = \sum_{i=1}^N w_i x_i - h$$

$$y = f(s) = \begin{cases} 1 & (s \geq 0) \\ 0 & (otherwise) \end{cases}$$


活性化関数はステップ関数

誤差関数 $E = \frac{1}{2}(y - y_d)^2$



学習則 $\Delta w_i =$

$=$

$=$



活性化関数を線形関数に




誤差関数 $E = \frac{1}{2}(y - y_d)^2 = \frac{1}{2}(f(s) - y_d)^2$

学習則 $\Delta w_i =$


$$\begin{aligned} \Delta w_i &= -\epsilon \frac{\partial E}{\partial w_i} & \Delta h &= -\epsilon \frac{\partial E}{\partial h} \\ &= -\epsilon \frac{dE}{dy} \frac{dy}{ds} \frac{\partial s}{\partial w_i} & &= -\epsilon \frac{dE}{dy} \frac{dy}{ds} \frac{\partial s}{\partial h} \\ &= -\epsilon (y - y_d) x_i & &= \epsilon (y - y_d) \end{aligned}$$

活性化関数をシグモイド関数に




$$s = \sum_{i=1}^N w_i x_i - h$$

$$y =$$



活性化関数をシグモイド関数に



誤差関数 $E =$


学習則 $\Delta w_i =$

$=$

$=$

$\frac{df}{ds} =$

活性化関数をシグモイド関数に



$$s = \sum_{i=1}^N w_i x_i - h$$

$$y =$$

$$f(s) = \frac{1}{1 + \exp(-s/T)} \quad (T: \text{定数})$$

誤差関数 $E =$

$$E = \frac{1}{2}(y - y_d)^2$$

学習則 $\Delta w_i =$

$$\Delta w_i = -\epsilon \frac{\partial E}{\partial w_i}$$

$$= -\epsilon \frac{dE}{dy} \frac{dy}{ds} \frac{\partial s}{\partial w_i}$$



$$= -\epsilon(y - y_d) \frac{dy}{ds} x_i$$

$$\frac{df}{ds} =$$

$$\frac{1}{T} \frac{\exp(-\frac{s}{T})}{(1 + \exp(-\frac{s}{T}))^2}$$



$$\begin{array}{c}
 x_1 \text{---} w_1 \\
 x_2 \text{---} w_2
 \end{array}
 \bigcirc \theta \text{---} y
 \qquad
 s = \sum_{i=1}^2 w_i x_i - h \quad y = f(s)$$

ステップ関数



二値分類

恒等関数



テキスト

シグモイド関数

